

Rapport pipeline - Mexora RH Intelligence

1. Objectif du pipeline

Ce document presente les traitements realises dans le pipeline Data Lake du projet Mexora RH Intelligence.

L'objectif du pipeline est de transformer des offres d'emploi IT marocaines brutes en donnees propres et exploitables pour l'analyse du marche de l'emploi IT au Maroc.

Le pipeline suit l'architecture suivante :

Donnees sources

- > Zone Bronze : donnees brutes conservees en JSON
- > Zone Silver : donnees nettoyees et standardisees en Parquet
- > Zone Gold : tables analytiques pour DuckDB et le rapport final

Ma partie concerne principalement :

- l'ingestion Bronze ;
- le chargement depuis Bronze ;
- le nettoyage Silver ;
- l'extraction des competences IT ;
- la sauvegarde des donnees Silver au format Parquet.

Les parties Gold, analyse DuckDB, visualisations et recommandations seront completees par la suite.

2. Donnees sources utilisees

Les fichiers sources sont places dans le dossier :

```
data/raw/
```

Fichiers utilises :

```
data/raw/offres_emploi_it_maroc.json
data/raw/referentiel_competences_it.json
data/raw/entreprises_it_maroc.csv
```

Le fichier principal `offres_emploi_it_maroc.json` contient les offres d'emploi IT avec des champs comme :

- `id_offre`
- `source`
- `titre_poste`

- `description`
- `competences_brut`
- `entreprise`
- `ville`
- `type_contrat`
- `experience_requise`
- `salaire_brut`
- `date_publication`
- `date_expiration`

Les donnees contiennent volontairement des imperfections afin de simuler des donnees issues du scraping :

- villes ecrites sous plusieurs formes : `casa`, `CASABLANCA`, `Casablanca` ;
- salaires sous plusieurs formats : `15000-20000 MAD`, `15K-20K`, `Selon profil`, `Confidentiel`, `2000 EUR` ;
- types de contrat non standardises : `CDI`, `cdi`, `Permanent`, `Contrat a duree indeterminee` ;
- experiences sous plusieurs formats : `3-5 ans`, `min 3 ans`, `Debutant accepte`, `Senior 7+ ans` ;
- competences melangees entre le champ `competences_brut` et la description.

3. Ingestion Bronze

Fichier concerne

```
pipeline/bronze_ingestion.py
```

Fonction principale

```
ingerer_bronze(filepath_source, data_lake_root)
```

Objectif

L'objectif de cette etape est de charger les donnees brutes dans la zone Bronze sans les modifier.

La zone Bronze sert d'archive fidele des donnees recues. Aucune correction n'est appliquee a cette etape.

Regles appliquees

Pour chaque offre :

1. lire la source de l'offre ;
2. lire la date de publication ;
3. extraire le mois au format `YYYY_MM` ;
4. creer une partition par `source/mois` ;
5. sauvegarder les offres dans un fichier `offres_raw.json`.

Exemple de structure generee :

```
data_lake/bronze/rekrute/2024_01/offres_raw.json
data_lake/bronze/linkedin/2024_02/offres_raw.json
data_lake/bronze/marocannonce/2024_03/offres_raw.json
```

Metadonnees ajoutees

Chaque fichier Bronze contient une section **metadata** avec :

- le fichier source ;
- la date d'ingestion ;
- la partition ;
- le nombre d'offres dans la partition.

Resultat obtenu sur le jeu de test

```
6 offres ingerees dans 6 partitions
```

Repartition observee :

```
rekrute : 2 offres
linkedin : 2 offres
marocannonce : 2 offres
```

Points d'attention

- Les donnees Bronze ne doivent pas etre modifiees.
- Si une date est invalide, la partition utilisee est **date_inconnue**.
- La zone Bronze n'est pas versionnee dans Git car elle peut etre regeneree.

4. Chargement depuis Bronze

Fichier concerne

```
pipeline/silver_transform.py
```

Fonction principale

```
charger_depuis_bronze(data_lake_root)
```

Objectif

Cette etape lit tous les fichiers Bronze et les regroupe dans un seul tableau pandas afin de commencer les transformations Silver.

Regles appliquees

Le pipeline parcourt tous les fichiers :

```
data_lake/bronze/**/offres_raw.json
```

Puis il :

1. lit chaque fichier JSON ;
2. extrait la liste des offres ;
3. fusionne les offres dans un seul DataFrame ;
4. supprime les doublons avec la colonne `id_offre`.

Resultat attendu

Sur le jeu de test :

```
6 offres chargees depuis Bronze  
0 doublons supprimes
```

Points d'attention

- La colonne `id_offre` est essentielle pour detecter les doublons.
- Les donnees originales ne sont pas encore nettoyees a cette etape.

5. Transformations Silver

Fichier concerne

```
pipeline/silver_transform.py
```

Objectif

La zone Silver contient des donnees nettoyees, standardisees et exploitables pour les analyses.

Les colonnes originales sont conservees quand elles sont utiles, et de nouvelles colonnes standardisees sont ajoutees.

5.1 Normalisation des villes

Fonction

```
normaliser_villes(df)
```

Regles appliquees

Une nouvelle colonne `ville_std` est creee.

Exemples :

```
casa -> Casablanca  
CASABLANCA -> Casablanca  
Casablanca -> Casablanca  
rabat -> Rabat  
RABAT -> Rabat  
tanger -> Tanger
```

Une colonne `region_admin` est aussi ajoutee.

Exemples :

```
Casablanca -> Casablanca-Settat  
Rabat -> Rabat-Sale-Kenitra  
Tanger -> Tanger-Tetouan-Al Hoceima
```

Colonnes ajoutees

```
ville_source  
ville_std  
region_admin
```

Point d'attention

La colonne originale `ville` est conservee pour garder la trace de la donnee source.

5.2 Normalisation des types de contrat

Fonction

```
normaliser_types_contrat(df)
```

Regles appliquees

Une nouvelle colonne `type_contrat_std` est creee.

Exemples :

```
CDI -> CDI
cdi -> CDI
Permanent -> CDI
Contrat a duree indeterminee -> CDI
Freelance -> Freelance
CDD -> CDD
Stage -> Stage
```

Colonne ajoutee

```
type_contrat_std
```

Point d'attention

Les valeurs non reconnues sont classees dans `Autre`.

5.3 Normalisation des titres de poste

Fonction

```
nettoyer_titres_postes(df)
```

Objectif

Standardiser les intitules de poste en familles de profils IT.

Regles appliquees

Une colonne `profil_normalise` est creee a partir du champ `titre_poste`.

Exemples :

```
Data Engineer Junior -> Data Engineer
Ingenieur Big Data -> Data Engineer
Data Analyst Power BI -> Data Analyst
BI Analyst -> Data Analyst
Data Scientist NLP -> Data Scientist
Developpeur Full Stack React Node.js -> Developpeur Full Stack
```

Colonnes ajoutees

```
profil_source  
profil_normalise
```

Point d'attention

Les titres non reconnus sont classes dans **Autre IT**.

5.4 Normalisation des salaires

Fonction

```
normaliser_salaires(df)
```

Objectif

Transformer les salaires textuels en valeurs numeriques en MAD mensuel brut.

Regles appliquees

Exemples :

```
12000-16000 MAD -> min 12000, max 16000, median 14000  
15K-20K -> min 15000, max 20000, median 17500  
2000 EUR -> conversion en MAD avec 1 EUR = 10.8 MAD  
Selon profil -> salaire inconnu  
Confidentiel -> salaire inconnu
```

Colonnes ajoutees

```
salaire_min_mad  
salaire_max_mad  
salaire_connu  
salaire_median_mad
```

Points d'attention

- Les salaires en EUR sont convertis avec un taux fixe de **1 EUR = 10.8 MAD**.
- Les valeurs non exploitables sont marquees avec **salaire_connu = False**.
- Les salaires incoherents sont ignores.

5.5 Normalisation de l'experience

Fonction

```
normaliser_experience(df)
```

Objectif

Transformer l'experience demandee en annees minimum et maximum.

Regles appliquees

Exemples :

```
1-2 ans -> min 1, max 2  
3-5 ans -> min 3, max 5  
min 3 ans -> min 3, max vide  
Debutant accepte -> min 0, max 2  
Senior 7+ ans -> min 7, max vide
```

Colonnes ajoutees

```
experience_min_ans  
experience_max_ans
```

Point d'attention

Les valeurs impossibles a interpreter restent vides afin de ne pas fausser les analyses.

5.6 Normalisation des dates

Fonction

```
normaliser_dates(df)
```

Objectif

Convertir les dates textuelles en dates exploitables et ajouter des colonnes temporelles.

Regles appliquees

Le pipeline convertit :


```
date_publication  
date_expiration
```

en :

```
date_publication_clean  
date_expiration_clean
```

Puis il ajoute :

```
annee  
mois  
date_valide
```

La colonne `date_valide` vaut `False` si :

- une date est absente ;
- une date est invalide ;
- la date de publication est apres la date d'expiration.

6. Extraction des competences IT

Fichier concerne

```
pipeline/silver_nlp.py
```

Fonction principale

```
extraire_compétences(df, referentiel_path)
```

Objectif

Extraire les competences IT presentes dans les offres afin de produire une table structuree exploitable pour les analyses.

Source utilisee

Le pipeline utilise le referentiel :

```
data/raw/referentiel_compétences_it.json
```

Ce fichier contient des familles de compétences et leurs alias.

Exemple :

```
python : python, python3, py
power_bi : power bi, powerbi, pbi
spark : spark, apache spark, pyspark
```

Regles appliquees

Pour chaque offre :

1. concatener **compétences_brut** et **description** ;
2. normaliser le texte ;
3. chercher les alias presents dans le referentiel ;
4. produire une ligne par compétence detectee ;
5. ajouter **non_detecte** si aucune compétence n'est trouvee.

Colonnes produites

```
id_offre
profil
ville
compétence
famille
date_pub
annee
mois
```

Points d'attention

- Les alias sont tries du plus long au plus court pour eviter des detections incorrectes.
- Les alias tres courts sont ignores pour limiter les faux positifs.
- Une meme compétence n'est ajoutée qu'une seule fois par offre.

7. Sauvegarde Silver

Fichier concerne

```
pipeline/silver_transform.py
```

Fonction principale

```
sauvegarder_silver(df_offres, df_compétences, data_lake_root)
```

Objectif

Sauvegarder les données nettoyées au format Parquet.

Fichiers générés

```
data_lake/silver/offres_clean/offres_clean.parquet  
data_lake/silver/competences_extraites/competences.parquet
```

Pourquoi Parquet ?

Le format Parquet est utilisé car il est :

- compressé ;
- rapide à lire ;
- adapté aux traitements analytiques ;
- compatible avec pandas, pyarrow et DuckDB.

Point d'attention

Les fichiers Parquet sont générés localement et ne sont pas obligatoirement versionnés dans GitHub, car ils peuvent être reconstruits avec :

```
python main.py
```

8. Exécution du pipeline

Fichier concerné

```
main.py
```

Ordre d'exécution

Le fichier `main.py` exécute les étapes dans cet ordre :

1. Ingestion Bronze
2. Chargement depuis Bronze

3. Normalisation des villes
4. Normalisation des types de contrat
5. Normalisation des titres de poste
6. Normalisation des salaires
7. Normalisation de l'experience
8. Normalisation des dates
9. Extraction des competences
10. Sauvegarde Silver

Commande de lancement

```
python main.py
```

9. Sorties disponibles pour la suite du projet

Les fichiers Silver suivants sont fournis a la partie Gold et analyse :

```
data_lake/silver/offres_clean/offres_clean.parquet  
data_lake/silver/competences_extraites/competences.parquet
```

Ces fichiers seront utilises pour :

- calculer les top competences ;
- analyser les salaires par profil ;
- comparer les villes ;
- identifier les entreprises qui recrutent le plus ;
- construire les tendances mensuelles.

10. Construction de la zone Gold

Fichier concerne

```
pipeline/gold_aggregation.py
```

Fonction principale

```
construire_gold(data_lake_root)
```

Objectif

La zone Gold contient des données analytiques agrégées prêtes pour les requêtes DuckDB, les visualisations, le notebook d'analyse ainsi que les recommandations finales du projet.

Contrairement à la zone Silver qui conserve les données nettoyées à un niveau détaillé, la zone Gold produit des indicateurs synthétiques facilitant l'analyse du marché IT marocain.

Sources utilisées

Les tables Gold sont construites à partir des fichiers Silver suivants :

```
data_lake/silver/offres_clean/offres_clean.parquet
data_lake/silver/competences_extraites/competences.parquet
```

Regles appliquées

Le pipeline réalise plusieurs agrégations analytiques :

1. calcul des compétences IT les plus demandées ;
2. calcul des salaires médians par profil ;
3. calcul du nombre d'offres par ville ;
4. identification des entreprises recrutant le plus ;
5. calcul des tendances mensuelles des profils IT.

Fichiers générés

```
data_lake/gold/top_competences.parquet
data_lake/gold/salaires_par_profil.parquet
data_lake/gold/offres_par_ville.parquet
data_lake/gold/entreprises_recruteurs.parquet
data_lake/gold/tendances_mensuelles.parquet
```

Pourquoi Parquet ?

Le format Parquet est utilisé dans la zone Gold car il permet :

- une lecture rapide avec DuckDB ;
- une meilleure compression des données ;
- une exécution efficace des agrégations ;
- une compatibilité avec pandas, matplotlib et les notebooks analytiques.

Point d'attention

Les tables Gold ne remplacent pas les données Silver. Elles représentent une version analytique simplifiée construite à partir des données nettoyées afin de répondre aux besoins décisionnels de Mexora.

11. Analyse DuckDB

Fichier concerne

```
analysis/analyse_marche.py
```

Objectif

DuckDB est utilisé afin d'exécuter des requêtes analytiques directement sur les fichiers Parquet sans utiliser une base de données relationnelle classique.

Cette approche permet d'analyser rapidement le marché de l'emploi IT marocain à partir des données produites dans le Data Lake.

Questions analytiques traitees

Les analyses réalisées répondent aux cinq questions stratégiques définies dans le cahier des charges du projet.

11.1 Quelles competences sont les plus demandees ?

Cette analyse mesure les compétences apparaissant le plus fréquemment dans les offres IT.

Objectif :

```
Identifier les technologies prioritaires du marche IT marocain
```

Exemples de compétences observées :

```
Python  
SQL  
Spark  
Power BI  
Docker
```

Cette analyse permet d'identifier les compétences techniques devant être priorisées dans les futurs recrutements de Mexora.

11.2 Tanger vs Casablanca vs Rabat : ou se trouvent les opportunités IT ?

Cette analyse compare le volume d'offres d'emploi entre les principales villes IT marocaines.

Objectif :

```
Comparer les bassins d'emploi technologique
```

Cette question est particulièrement stratégique pour Mexora basée à Tanger, car elle permet d'évaluer si certains profils devront être recrutés localement ou à distance depuis d'autres villes.

11.3 Quel est le salaire median par profil IT ?

Cette analyse mesure les niveaux de rémunération observés selon les profils IT.

Objectif :

Positionner les futurs packages salariaux de Mexora

Les salaires médians observés permettent d'estimer des niveaux de rémunération cohérents avec le marché afin de rester compétitif dans le recrutement.

11.4 Existe-t-il une relation entre experience et salaire ?

Une corrélation de Pearson est calculée entre :

experience_min_ans
salaire_median_mad

Objectif :

Mesurer l'impact de l'experience sur les niveaux de remuneration

Cette analyse permet de vérifier si une augmentation du niveau d'expérience demandé tend à être associée à des salaires plus élevés.

11.5 Quelles entreprises recrutent le plus ?

Cette analyse identifie les entreprises publiant le plus d'offres IT.

Objectif :

Identifier les concurrents de Mexora sur le marche du talent

Les entreprises les plus actives en recrutement représentent une concurrence potentielle sur les profils data et IT.

12. Visualisations et dashboard

Fichier concerne

```
notebooks/analyse_marche_it_maroc.ipynb
```

Objectif

Le notebook contient un dashboard analytique synthétisant les principaux résultats du marché IT marocain.

Visualisations realisees

12.1 Top competences IT

Graphique horizontal présentant les compétences les plus demandées dans les offres IT.

Objectif :

```
Identifier les technologies prioritaires du marche
```

12.2 Comparaison Tanger / Casablanca / Rabat

Graphique comparatif du volume d'offres selon les villes.

Objectif :

```
Comparer les opportunités IT selon les bassins d'emploi
```

12.3 Salaires mediens par profil

Graphique montrant les rémunérations médianes selon les profils IT.

Objectif :

```
Comparer les niveaux de salaire du marche
```

12.4 Evolution mensuelle des profils data

Courbe temporelle représentant les profils :

```
Data Engineer  
Data Analyst  
Data Scientist
```


Objectif :

Identifier les tendances de recrutement dans le temps

Point d'attention

Le dashboard est intégré directement au notebook d'analyse via matplotlib, conformément aux consignes du projet.

13. Limites du projet

Certaines limites doivent être prises en compte dans l'interprétation des résultats :

- le dataset reste issu du scraping et peut contenir du bruit ;
- certaines offres ne renseignent pas le salaire ;
- certaines compétences peuvent ne pas être détectées si elles ne figurent pas dans le référentiel ;
- le nombre d'offres peut varier selon les plateformes utilisées ;
- certaines informations manquantes peuvent limiter certaines analyses statistiques.

Malgré ces limites, les analyses produites permettent d'obtenir une vision cohérente du marché IT marocain.

14. Recommandations pour Mexora

À partir des résultats obtenus, plusieurs recommandations peuvent être formulées :

- cibler les compétences les plus demandées dans les futurs recrutements ;
- proposer des rémunérations cohérentes avec les médianes observées sur le marché ;
- renforcer le recrutement sur Casablanca et Rabat si certains profils sont rares localement ;
- anticiper les périodes de forte demande sur les profils data ;
- développer une stratégie attractive afin de concurrencer les entreprises les plus actives du marché du talent IT.